

This is a multilingual test document for RAG document parsing.
本测试文档用于验证 RAG 系统对多格式文档的解析能力。

LangChain provides a unified interface for document loading,
splitting, and retrieval. 它支持多种文件格式的解析。

Key concepts:

1. Document Loading — 文档加载
2. Text Splitting — 文本分割
3. Embedding & Retrieval — 嵌入与检索

In natural language processing, tokenization is the process of
splitting text into smaller units. 分词是自然语言处理中的基础步骤。

The system uses a strategy pattern to route different file formats to appropriate document loaders.

系统使用策略模式将不同格式路由到相应的文档加载器。

Supported formats include PDF, Word, Excel, PowerPoint, Markdown, and plain text files.

支持的格式包括 PDF、Word、Excel、PPT、Markdown 和纯文本。

Vector databases are a key component of RAG systems.

向量数据库是 RAG 系统的核心组件之一。

They convert text into vector representations for efficient similarity search. 它们将文本转换为向量表示，支持相似度搜索。

Common embedding models include text-embedding-ada-002, bge-large-zh-v1.5, and other open-source alternatives.

常用的 Embedding 模型包括 text-embedding-ada-002、bge-large-zh-v1.5 等。

Testing ensures that all document formats can be correctly loaded with proper page/paragraph segmentation and no character corruption. 测试确保所有格式的文档能被正确加载，分段合理，中文字符无乱码。

Future enhancements: OCR for scanned documents, incremental loading, caching mechanisms, and parallel parsing. 未来改进方向：OCR 扫描件支持、增量加载、缓存机制和并行解析。

Thank you for using the Multi-Format Document Loader! 感谢使用多格式文档加载器！